
Practica Nifi

https://localhost:8443/nifi


1) En el shell de Nifi, crear un script .sh que descargue el archivo titanic.csv al directorio /home/nifi/ingest (crearlo si es necesario). Ejecutarlo con ./home/nifi/ingest/ingest.sh


```
nifi@332d81692629:~/ingest$ ls
ingest_Parquet.sh ingest.sh titanic.csv
nifi@332d81692629:~/ingest$
```

- 2) Usando procesos en Nifi:
- 3) tomar el archivo titanic.csv desde el directorio /home/nifi/ingest.
- 4) Mover el archivo titanic.csv desde el directorio anterior, a /home/nifi/bucket (crear el directorio si es necesario)
- 5) Tomar nuevamente el archivo, ahora desde /home/nifi/bucket
- 6) Ingestarlo en HDFS/nifi (si es necesario, crear el directorio con hdfs dfs -mkdir /nifi)









```
hadoop@ec27db0d59e9:/$ hdfs dfs -ls /nifi
Found 1 items
-rw-r--r-- 1 nifi supergroup 60353 2024-06-04 20:29 /nifi/titanic.csv
hadoop@ec27db0d59e9:/$
```

- 7) Una vez que tengamos el archivo titanic.csv en HDFS realizar un pipeline en Airflow que ingeste este archivo y lo cargue en HIVE, teniendo en cuenta las siguientes transformaciones:
 - a) Remover las columnas SibSp y Parch
 - b) Por cada fila calcular el promedio de edad de los hombres en caso que sea hombre y promedio de edad de las mujeres en caso que sea mujer
 - c) Si el valor de cabina en nulo, dejarlo en 0 (cero)

CREATE EXTERNAL TABLE titanic.information(passengerId int, survived int, pclass tinyint, name string, sex string, age int, ticket string, fare float, cabin string, embarked string, avg_age_by_sex double)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY ','
LOCATION '/tables/external/titanic/information';

```
hive> use titanic;
OK
Time taken: 0.04 seconds
hive> show tables;
OK
information
Time taken: 0.058 seconds, Fetched: 1 row(s)
hive>
```



DAG: ingest-transform-load-clase-diez

```
⊞ Grid 📲 Graph 🛅 Calendar 🙎 Task Duration 🚅 Task Tries 👱 Landing Times 📃 Gantt 🛕 Details
                                                                                                                                                      <> Code
                                                                                                                                                                     Audit Log
   1 from datetime import timedelta
2 from airflow import DAG
       from airflow.operators.bash import BashOperator
from airflow.operators.dummy import DummyOperator
from airflow.utils.dates import days_ago
   7 args = {
            'owner': 'airflow'.
   11 with DAG(
           dag_id='ingest-transform-load-clase-diez',
           default_args=args,
schedule_interval='0 0 * * *',
           start_date=days_ago(2),
dagrun_timeout=timedelta(minutes=60),
           tags=['ingest', 'transform'],
params={"example_key": "example_value"},
  18 params
19 ) as dag:
           inicia_proceso = DummyOperator(
          task_id='inicia_proceso',
  24
           task_id='finaliza_proceso',
)
           ingest_transform_load = BashOperator(
    task_id='ingest_transform_load',
  31
                bash_command='ssh hadoop@172.17.0.2 /home/hadoop/spark/bin/spark-submit --files /home/hadoop/hive/conf/hive-site.xml /home/hadoop/scripts/transform_clase_diez.py ',
  33
            inicia proceso >> ingest transform load >> finaliza proceso
```

Resultado en Hive:

