
Practica Nifi

https://localhost:8443/nifi


1) En el shell de Nifi, crear un script .sh que descargue el archivo titanic.csv al directorio /home/nifi/ingest (crearlo si es necesario). Ejecutarlo con ./home/nifi/ingest/ingest.sh


```
nifi@332d81692629:~/ingest$ ls
ingest_Parquet.sh ingest.sh titanic.csv
nifi@332d81692629:~/ingest$
```

- 2) Usando procesos en Nifi:
- 3) tomar el archivo titanic.csv desde el directorio /home/nifi/ingest.
- 4) Mover el archivo titanic.csv desde el directorio anterior, a /home/nifi/bucket (crear el directorio si es necesario)
- 5) Tomar nuevamente el archivo, ahora desde /home/nifi/bucket
- 6) Ingestarlo en HDFS/nifi (si es necesario, crear el directorio con hdfs dfs -mkdir /nifi)









```
hadoop@ec27db0d59e9:/$ hdfs dfs -ls /nifi
Found 1 items
-rw-r--r-- 1 nifi supergroup 60353 2024-06-04 20:29 /nifi/titanic.csv
hadoop@ec27db0d59e9:/$
```

- 7) Una vez que tengamos el archivo titanic.csv en HDFS realizar un pipeline en Airflow que ingeste este archivo y lo cargue en HIVE, teniendo en cuenta las siguientes transformaciones:
 - a) Remover las columnas SibSp y Parch
 - b) Por cada fila calcular el promedio de edad de los hombres en caso que sea hombre y promedio de edad de las mujeres en caso que sea mujer
 - c) Si el valor de cabina en nulo, dejarlo en 0 (cero)

```
| from pyspark.context import SparkEcontext
| from pyspark.sql.sipsort import SparkEcosion
| from pyspark.sql.sipsort.sipsort sparkEcosion
| from pyspark.sql.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.sipsort.s
```


CREATE EXTERNAL TABLE titanic.information(passengerId int, survived int, pclass tinyint, name string, sex string, age int, ticket string, fare float, cabin string, embarked string, avg_age_by_sex double)

ROW FORMAT DELIMITED

FIELDS TERMINATED BY ','


LOCATION '/tables/external/titanic/information';

```
hive> use titanic;
OK
Time taken: 0.04 seconds
hive> show tables;
OK
information
Time taken: 0.058 seconds, Fetched: 1 row(s)
hive>
```




	123 passengerid 🔻	123 survived 🔻	123 pclass	_	ADC name	ADC sex	J	123 age 🔻	,	ADC ticket 🔻	123 fare •	ADC cabin 🔻	ADC embarked 🔻	123 avg_age_by_sex
	494	0			Artagaveytia Mr. Ramon	male				PC 17609	49.5042		C	30.7
4	673	0			Mitchell Mr. Henry Michael	male				C.A. 24580	10.5		S	30.7
2	746				Crosby Capt. Edward Gifford	male				WE/P 5735		B22		30.7
7	117	0			Connors Mr. Patrick	male				370369	7.75		Q	30.7
7					Wheadon Mr. Edward H	male				C.A. 24579	10.5		S	30.7
9	457	0			Millet Mr. Francis Davis	male				13509	26.55			30.7
	55					male				113509	61.9792			30.7
10	281	0			Ostby Mr. Engelhart Cornelius Duane Mr. Frank	male				336439	7.75		Q	30.7
11	546				Nicholson Mr. Arthur Ernest	male				693	26		s	30.7
12	439				Fortune Mr. Mark	male				19950	263	C23 C25 C27		30.7
13	439 276				Andrews Miss, Kornelia Theodosia	female				13502	77.9583			27.9
14	484									4134	9.5875			27.9
15	484				Turkula Mrs. (Hedwig)	female				113514	9.5875 26.55			
16	830				Stead Mr. William Thomas	male				113514		E28		30.7
17					Stone Mrs. George Nelson (Martha Evelyn)	female								27.9
18	571				Harris Mr. George	male				S.W./PP 752	10.5			30.7
19	556				Wright Mr. George	male				113807	26.55			30.7
20	626				Sutton Mr. Frederick	male	_			36963	32.3208			30.7
21	171				Van der hoef Mr. Wyckoff	male	_			111240				30.7
22					Nysveen Mr. Johan Hansen	male				345364	6.2375			30.7
23	695				Weir Col. John	male				113800	26.55			30.7
24	685				Brown Mr. Thomas William Solomon	male				29750				30.7
25	367				Warren Mrs. Frank Manley (Anna Sophia Atl					110813	75.25			27.9
26	588				Frolicher-Stehli Mr. Maxmillian	male				13567	79.2			30.7
27	233				Sjostedt Mr. Ernst Adolf	male				237442	13.5			30.7
28					Coxon Mr. Daniel	male				364500	7.25			30.7
29	488				Kent Mr. Edward Austin	male				11771	29.7	B37		30.7
30	660				Newell Mr. Arthur Webster	male					113.275			30.7
31					Bonnell Miss. Elizabeth	female				113783	26.55	C103		27.9
32	269				Graham Mrs. William Thompson (Edith Juni					PC 17582		C125		27.9
33	196				Lurette Miss. Elise	female				PC 17569	146.5208	B80		27.9
34					Mack Mrs. (Mary)	female				S.O./P.P. 3				27.9
35					Kirkland Rev. Charles Leonard	male		5		219533	12.35			30.7
36	880				Potter Mrs. Thomas Jr (Lily Alexenia Wilson)	female					83.1583			27.9
37	468				Smart Mr. John Montgomery	male			6	113792	26.55			30.7


- 8) Una vez con la información en el datawarehouse calcular:
 - a) Cuántos hombres y cuántas mujeres sobrevivieron



b) Cuántas personas sobrevivieron según cada clase (Pclass)



c) Cuál fue la persona de mayor edad que sobrevivió



d) Cuál fue la persona más joven que sobrevivió

